

凸优化是数值优化中强调凸的部分

数值优化中 $\begin{cases} \text{带约束优化} \\ \text{无约束优化} \end{cases}$ 但是重点在数值上, 例如 $\begin{cases} f_1(x)=0 \\ \vdots \\ f_n(x)=0 \end{cases} \Rightarrow \min \sum_{i=1}^n f_i^2(x)$

例子1: Linear Quadratic Regulator: $x_k = Ax_{k-1} + Bu_k$

$\min_{\{u_k\}} \sum_{k=1}^n (\underline{x_k^T Q x_k} + \underline{u_k^T R u_k})$, 线性二次调节器

x_k 是状态集合, u_k 是状态输入 $\rightarrow$ 状态的方差/输入的方差

例子2. 2d-fused LASSO: $\min_{\theta} \frac{1}{2} \sum_{i=1}^n (y_i - \theta_i)^2 + \lambda \sum_{i=1}^{n-1} |\theta_i - \theta_{i+1}|$. y_i 为数据点,
希望回归时 值变化幅度小; 且不要频繁变化

例子3: PCA. $\min_R \|X - R\|_F^2$, s.t. $r(R) = k$, $X \in \mathbb{R}^{n \times p}$

$R = U_k D_k V_k^T$, 但是 $r(R) = k$ 是一个非凸集, 所以是一个非凸优化
(两个秩为1的矩阵相加秩不一定为1)


基础概念

Affine combination $x = \theta x_1 + (1-\theta)x_2$

E.g. $\{x \mid Ax = b\}$

affine set: contains the line through any two distinct in the set

convex set: $\forall x_1, x_2 \in C, 0 \leq \theta \leq 1, \theta x_1 + (1-\theta)x_2 \in C$



$\emptyset$ 也是凸集

convex combination: of $x_1, \dots, x_n \in A$, 线段

$$x = \theta_1 x_1 + \dots + \theta_n x_n, \quad \theta_i \geq 0, \sum \theta_i = 1.$$

convex hull: A set of all convex combination of points from that set



x 是 convex combination

A convex hull of a set is the smallest convex set contain the set

Hyperplane/halfspace: they are convex

例: 设 $A \in \mathbb{R}^{m \times n}$, 证明如果 $S \subset \mathbb{R}^m$ 是 convex set, 那么 $A^{-1}(S) = \{x \in \mathbb{R}^n, Ax \in S\}$

是 convex set: $\forall y_1, y_2 \in A^{-1}(S), A(\theta y_1 + (1-\theta)y_2) = \theta Ay_1 + (1-\theta)Ay_2 \in S$

凸集在线性映射下的原象集

类似的如果 S 是 convex set, $AS = \{Ax \mid x \in S\}$ 也是 convex set

例: X_1 与 X_2 是凸集, 证明 $X_1 + X_2$ 是凸集: $X_1 \times X_2 = \{(x_1, x_2) \mid x_1 \in X_1, x_2 \in X_2\}$
 而 $f(x_1, x_2) = x_1 + x_2$ 是线性映射, 是凸的, 所以经一后凸性保持不变.

{ Euclidean balls: $B(x_c, r) = \{x \mid \|x - x_c\| \leq r\}$
 ellipsoids $\{x \mid (x - x_c)^T P^{-1} (x - x_c) \leq 1\}$ P 是对称且正定的
 Norm ball, norm cone $\{(x, t) \mid \|x\| \leq t\}$

证明 ellipsoid 是凸集, 令 $u = P^{-\frac{1}{2}}(x - x_c)$, 得到球 $u^T u = 1$, 由于是线性, 说明是凸集


polyhedra 多面体: $Ax \leq b, Cx = d \Rightarrow \{x \mid Ax \leq b, Cx \leq d, -Cx \leq -d\}$
 $\Rightarrow \begin{bmatrix} A \\ C \\ -C \end{bmatrix} x \leq \begin{bmatrix} b \\ d \\ -d \end{bmatrix}$

Cone: 设 $C \in \mathbb{R}^n$, $x \in C \Rightarrow tx \in C, \forall t \geq 0$

Convex Cone: $x_1, x_2 \in C, \Rightarrow t_1 x_1 + t_2 x_2 \in C, \forall t_1, t_2 \geq 0$

Conic Combination: $x_1, \dots, x_k, \sum_{i=1}^k \theta_i x_i, \theta_i \geq 0, \sum \theta_i = 1$

Conic hull: 所有的 Conic Combination.



例: 证明单纯形为一个多面体

单纯形: $\Delta = \{x \in \mathbb{R}^n \mid x = \sum_{i=0}^k \theta_i v_i, \sum_{i=0}^k \theta_i = 1\}$, $v_1 - v_0, \dots, v_k - v_0$ 线性无关

核心: 证明单纯形可以表示为有限个不等式的交

证明一:

定义 $[v_1 - v_0, \dots, v_k - v_0] = B \in \mathbb{R}^{n \times k}$

于是 $x = v_0 + B\theta$, B 是列满秩的, 构造 $A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \in \mathbb{R}^{n \times n}$, 使 $AB = \begin{bmatrix} I_k \\ 0 \end{bmatrix}$

于是
$$\begin{cases} A_1 x = A_1 v_0 + \theta \\ A_2 x = A_2 v_0 \end{cases} \Rightarrow \begin{cases} A_1 x \geq A_1 v_0 \\ 1^T A_1 x \leq 1 + 1^T A_1 v_0 \\ A_2 x = A_2 v_0 \end{cases}$$

□

证明二: 定义仿射变换, $T: \mathbb{R}^{k+1} \rightarrow \mathbb{R}^n$, $T(\lambda) = \sum_{i=0}^k \lambda_i v_i$

标准单纯形: $\Delta^k = \{\lambda \in \mathbb{R}^{k+1} : \lambda_i \geq 0, \sum \lambda_i = 1\}$.

则 $T(\Delta^k) = \Delta$. T 是仿射变换, 只需说明 Δ^k 是多面体

而 $\Delta^k = \{\lambda : -\lambda_i \geq 0, i=0, \dots, k, \sum \lambda_i \leq 1, -\sum \lambda_i \leq -1\}$

□

性质: 可行域为有界多面体时, 目标函数的最大值在多面体顶点取到

证明: 设顶点集合为 $\{x_1, \dots, x_k\}$, 多面体中点可写成: $y = \sum \alpha_i x_i$, $\sum \alpha_i = 1$
 $f(\sum \alpha_i x_i) \leq \sum \alpha_i f(x_i) \leq \max \{f(x_1), \dots, f(x_n)\}$

证明一个集合是 convex set

1) definition

2) ① The intersection of convex set is convex. (交集性质)

例如: $\{x \mid |P(t)| \leq 1, t \in [0, \frac{\pi}{3}]\}$ $P(t) = x_1 \cos t + x_2 \cos 2t + \dots + x_m \cos mt$

$\{x \mid |P(0.6)| \leq 1\}$ 是 half space, 且原集合是各个 t 取值的交.

② Affine function f .

$S \in \mathbb{R}^n$ convex, $f(S) = \{f(x) \mid x \in S\}$ is convex

The inverse image of a convex set is convex.

$C \in \mathbb{R}^n$ convex; $f^{-1}(C) = \{x \in \mathbb{R}^n \mid f(x) \in C\}$ is convex.

一些常用到的函数:

perspective function $P: \mathbb{R}^{n+1} \rightarrow \mathbb{R}^n$ $P(x,t) = \frac{x}{t}$

$\text{dom } P = \{(x,t) \mid t > 0\}$

Linear-fraction function: $\frac{Ax+b}{c^T x+d}, c^T x+d > 0$

$$f(x) = \frac{x}{(x_1, x_2)x+1}$$

Generalized inequalities 使用特殊的锥定义不等式

K is closed, solid, pointed $\rightarrow$ proper cone 正交锥



$$x \preceq_K y \Leftrightarrow y-x \in K, \quad x \prec_K y \Leftrightarrow y-x \in \text{int } K$$

13) matrix inequality: $X \preceq_{S_+^n} Y \Leftrightarrow Y-X$ 是半正定的

x minimal element of S , $y \preceq_K x \quad \forall y \in S$.

Separating hyperplane theorem: 如果 C 与 D 是两个不交的凸集

$$\exists a \neq 0, b \text{ s.t. } a^T x \leq b \quad \forall x \in C \text{ and } a^T x \geq b \quad \forall x \in D$$



Support hyperplane theorem: supporting hyperplane to set C at the boundary point

$$x_0: \{x \mid a^T x = a^T x_0\} \quad \text{where } a \neq 0, \quad a^T x \leq a^T x_0, \quad \text{for all } x \in C$$

如果 C 是一个凸集, 对于边界上的每个点都有一个 support hyperplane

正交补: $V^\perp = \{x \mid y^T x = 0 \quad \forall y \in V\}$

对偶锥: $K^* = \{y \mid y^T x \geq 0, \quad \forall x \in K\}$

e.g. ① $\{0\}^* = \mathbb{R}^2$,

② ray^{*} 是 halfspace



③ 的对偶锥是其本身

使用 dual inequality 定义 minimum/minimal

minimum element: $\preceq_K$

x is the minimum element of S , iff for all $\lambda \succ_{K^*} 0$, x is the unique minimizer of $\lambda^T z$ over S .

if x minimize $\lambda^T z$ for some $\lambda \succ_{K^*} 0$, then x is minimal



Convex function: $f: \mathbb{R}^n \rightarrow \mathbb{R}$ if $\text{dom } f$ is a convex set and

$$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y) \quad \forall x, y \in \text{dom } f, 0 \leq \theta \leq 1$$

e.g. $\mathbb{R}^n$ ① $f(x) = a^T x + b$ ② $\|x\|_p$, for $p \geq 1$. $\|x\|_\infty = \max_k |x_k|$

$$\mathbb{R}^{m \times n} \text{ ① } f(x) = \text{tr}(A^T X) + b = \sum_i \sum_j A_{ij} X_{ij} + b$$

② spectral (maximum singular value) norm (谱范数)

$$f(x) = \|X\|_2 = \sigma_{\max}(X) = [\lambda_{\max}(X^T X)]^{\frac{1}{2}} \rightarrow \text{最大奇异值}$$

无论是凸函数还是凹函数, 定义域要求为凸集

凸函数的其他判断方式:

① 一阶定义

② 二阶定义

③ 在一点处限制

凸函数的一维刻画

(1) Restriction of a convex function to a line: 在给定点 $f(x)$ 后

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ is convex iff function $g: \mathbb{R} \rightarrow \mathbb{R}$, $g(t) = f(x+tv)$ is convex (in t)

$\text{dom } g = \{t \mid x+tv \in \text{dom } f\}$ for $\forall x \in \text{dom } f, v \in \mathbb{R}^n$

eg. $f(x) = \log(\det X)$ ($S^n \rightarrow \mathbb{R}$). $\text{dom } f = S_{++}^n$ (对称正定矩阵)

$$g(t) = \log \det(X+tv) = \log \det X + \log \det(I + tX^{-\frac{1}{2}}vX^{\frac{1}{2}}) = \log \det X + \sum_{i=1}^n \log(1+\lambda_i t)$$

g 对于 t 是 concave 的, 于是 f 是 concave 的 (其中 λ_i 为 $X^{-\frac{1}{2}}vX^{\frac{1}{2}}$ 的特征值)

(2) f 延拓后 ($x \notin \text{dom } f, \tilde{f}(x) = +\infty$)

$$0 \leq \theta \leq 1 \Rightarrow \tilde{f}(x\theta + (1-\theta)y) \leq \theta \tilde{f}(x) + (1-\theta) \tilde{f}(y).$$

说明 f is convex,

(3) 1st-order condition: 可导函数 f 在 C 上定义域是凸的 iff $f(y) \geq f(x) + \nabla f(x)^T(y-x)$
 $\forall x, y \in \text{dom} f$ (-阶条件对应的直线在函数下方)

证明: 与原始定义等价. $f(tx + (1-t)y) = f(y + t(x-y)) \leq tf(x) + (1-t)f(y)$

$$\Rightarrow f(x) - f(y) \geq \frac{f(y + t(x-y)) - f(y)}{t} \quad \lim_{t \rightarrow 0} \frac{f(y + t(x-y)) - f(y)}{t} = \nabla f(y)^T(x-y)$$

反过来 $\begin{cases} f(x) \geq f(z) + \nabla f(z)^T(x-z) \\ f(y) \geq f(z) + \nabla f(z)^T(y-z) \end{cases}$ 其中 $z = tx + (1-t)y$, 分别乘 t 与 $(1-t)$ 相加 $\square$

(4) Second-order conditions: twice differentiable f is convex iff
 $\nabla^2 f(x) \succeq 0 \quad \forall x \in \text{dom} f \quad (\nabla^2 f(x) \in S^n)$

证明: 反证, 则 $\exists x \in \text{dom} f$ 有 $\nabla^2 f(x) \not\succeq 0 \Rightarrow z^T \nabla^2 f(x) z < 0$

设 $y = x + tz$, 由于 - 阶满足 $f(x + tz) \geq f(x) + t \nabla f(x)^T z$; 二阶展开 f .
有 $\forall t, f(x + tz) = f(x) + t \nabla f(x)^T z + \frac{1}{2} t^2 z^T \nabla^2 f(x + \sigma t z) z, \sigma \in [0, 1]$

于是当 t 很小时 $z^T \nabla^2 f(x + \sigma t z) z < 0$, 与 - 阶条件矛盾. $\square$

E.g. quadratic function $f(x) = \frac{1}{2}x^T P x + q^T x + r$ ($P \in S^n$)

least square objective $f(x) = \|Ax - b\|_2^2$

例: quadratic-over-linear $f(x, y) = \frac{x^2}{y}$, is convex for $y > 0$

证明: $\nabla^2 f = \frac{2}{y^3} \begin{bmatrix} y \\ -x \end{bmatrix} \begin{bmatrix} y \\ -x \end{bmatrix}^T \geq 0$ (jointly convex)

注意: $f(x, y) = xy$ 不是 convex, $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 不是半正定的

例: 证明 $\min_x \max_y f(x, y)$ 是凸优化问题

sup/max 是 convex 的, 而最小化凸函数是凸优化

E.g. $f(x) = \log \sum_{k=1}^n \exp x_k$ is convex: $\nabla^2 f(x) = \frac{1}{1^T Z} \text{diag}(Z) - \frac{1}{1^T Z} Z Z^T$

实际应用中 $z_k = \frac{e^{x_k}}{\sum_{i=1}^n e^{x_i}}$, $\sum_{i=1}^n z_i = 1$. 为 softmax 形式


$\forall u$, $u^T \nabla^2 f(x) u \geq 0$, 使用柯西不等式 $\sum_{i=1}^n z_i \sum_{i=1}^n z_i u_i^2 - (\sum_{i=1}^n z_i u_i)^2$
 $\geq (\sum_{i=1}^n \sqrt{z_i} \sqrt{z_i} u_i)^2 - (\sum_{i=1}^n z_i u_i)^2 = 0$

e.g. $f(x) = \left(\prod_{k=1}^n x_k\right)^{\frac{1}{n}}$ on $\mathbb{R}_{++}^n$ is concave

(15) α -sublevel set of $f: \mathbb{R}^n \rightarrow \mathbb{R}$ $C_\alpha = \{x \in \text{dom} f \mid f(x) \leq \alpha\}$
sublevel set of a convex function is convex (反之不成立)

Epigraph. $f: \mathbb{R}^n \rightarrow \mathbb{R}$ $\text{epi} f = \{(x, t) \in \mathbb{R}^{n+1} \mid x \in \text{dom} f, f(x) \leq t\}$

f is convex if and only if its epigraph is a convex set.
Jensen's Inequality: f is convex then $f(Ez) \leq E f(z)$



凸性与光滑性: strong convexity: 若 $f(x) - \frac{m}{2} \|x\|^2$ 是一个凸函数,

那么 $f(x)$ 就是一个凸性度量为 m 的强凸函数

Smoothness: 如果 $\nabla f(x)$ 满足 $\forall x, y, \|\nabla f(x) - \nabla f(y)\| \leq \|x - y\|$

以下性质等价.

① f 强凸且凸性度量为 m .

$$\textcircled{2} (\nabla f(x) - \nabla f(y))^T (x - y) \geq m \|x - y\|^2 \quad \forall x, y$$

$$\textcircled{3} \nabla^2 f(x) \succeq mI, \quad \forall x$$

$$\textcircled{4} f(y) \geq f(x) + \nabla f(x)^T (y - x) + \frac{m}{2} \|y - x\|^2$$

Pointwise maximum: if $f_1, \dots, f_m$ are convex, $f(x) = \max \{f_1(x), \dots, f_m(x)\}$ is convex.

e.g. sum of r largest component of $x \in \mathbb{R}^n$

$f(x) = x_{[1]} + \dots + x_{[r]}$ is convex

(proof: $f(x) = \max \{x_{i_1} + x_{i_2} + \dots + x_{i_r} \mid 1 \leq i_1 \leq \dots \leq i_r \leq n\}$)

If $f(x, y)$ is convex in x for each $y \in A$, then $g(x) = \sup_{y \in A} f(x, y)$ is convex

Examples: ① support function: $S_C(x) = \sup_{y \in C} y^T x$ is convex

② distance to farthest point in a set C

③ maximum of eigenvalue of symmetric matrix: for $X \in S^n$

$$\lambda_{\max}(X) = \sup_{\|y\|_2=1} y^T X y \quad (y^T X y \text{ 对 } X \text{ 是 linear 的})$$

凹函数复合仍为凹的: $f(x) = -\sum_{i=1}^n \log(b_i - a_i^T x)$

$$f(x) = h(g(x)) \quad h: \mathbb{R} \rightarrow \mathbb{R}, \quad g: \mathbb{R}^n \rightarrow \mathbb{R}$$

f is convex if $\begin{cases} g \text{ convex}, h \text{ convex}, \tilde{h} \text{ 不减} \\ g \text{ concave}, h \text{ convex}, \tilde{h} \text{ 不增} \end{cases}$

(Proof: $f''(x) = h''(g(x))g'(x)^2 + h'(g(x))g''(x)$)

$$f(x) = h(g(x)) \quad g: \mathbb{R}^n \rightarrow \mathbb{R}^k, \quad h: \mathbb{R}^k \rightarrow \mathbb{R}$$

$$f''(x) = g'(x)^T \nabla^2 h(g(x)) g'(x) + \nabla h(g(x))^T g''(x)$$

相比标量版本 $\tilde{h}$ (延拓后) 对每个分量单调性成立.

E.g. $\log \sum_{i=1}^M \exp g_i(x)$ is convex if g_i are convex

E.g. $\frac{(1^T x)^2}{\min(2, \sqrt{x_3})}$ is convex

Minimization: if $f(x, y)$ is convex in (x, y) and C is a convex set, then

$$g(x) = \inf_{y \in C} f(x, y) \text{ is convex.}$$

局部最小化保持凸性

$$\begin{bmatrix} x \\ y \end{bmatrix}^T \begin{bmatrix} A & B \\ B^T & C \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} \in \mathbb{R}^n \quad \begin{bmatrix} A & B \\ B^T & C \end{bmatrix} \succeq 0, \quad C \succeq 0$$

$$g(x) = \inf_y f(x, y) = x^T (A - BC^{-1}B^T)x$$

由于 $x^T A x + 2x^T B y + y^T C y$ 是 joint convex 的, 于是可知 $A - BC^{-1}B^T \succeq 0$

The perspective of a function $f: \mathbb{R}^n \rightarrow \mathbb{R}$ is the function $g: \mathbb{R}^n \times \mathbb{R} \rightarrow \mathbb{R}$

$$g(x, t) = t f\left(\frac{x}{t}\right) \quad \text{dom } g = \left\{ (x, t) \mid \frac{x}{t} \in \text{dom } f, t > 0 \right\}$$

g is convex if f is convex.

应用: 由于 $f(x) = -\log x$ 是 convex 的, 于是 $g(x, t) = t \log t - t \log x$. 相对熵

The conjugate function: $f^*(y) = \sup_{x \in \text{dom } f} (y^T x - f(x))$ (proof: 对于 $y^T x - f(x)$ 是 affine, 对于 sup 保持凸性不变)

f^{**} 是 f 的凸包络.
共轭函数.

Example: strictly convex quadratic $f(x) = \frac{1}{2} x^T Q x$ with $Q \in S_{++}^n$

$$f^*(x) = \sup_x (y^T x - \frac{1}{2} x^T Q x) = \frac{1}{2} y^T Q^{-1} y$$

$$\left(\frac{d (y^T x - \frac{1}{2} x^T Q x)}{dx} = y - Qx = 0 \Rightarrow x = Q^{-1} y \right)$$

拟凸

Quasiconvex: $f: \mathbb{R}^n \rightarrow \mathbb{R}$ is quasiconvex if $\text{dom } f$ is convex and the sublevel set $S_\alpha = \{x \in \text{dom } f \mid f(x) \leq \alpha\}$ are convex for all α (拟凸)

例如 $\sqrt{|x|}$

Internal rate of return $\hat{=}$ cash flow $x = (x_0, \dots, x_n)$ $x_0 < 0, \sum x_i > 0$

$$PV(x, r) = \sum_{i=0}^n (1+r)^{-i} x_i, \quad IRR(x) = \inf \{r \geq 0 \mid PV(x, r) = 0\}$$

IRR is quasiconcave: superlevel set is a intersection of open halfspaces

$$IRR(x) \geq R \iff \sum_{i=0}^n (1+r)^{-i} x_i > 0 \text{ for } 0 \leq r \leq R$$

内部收益率

拟凹函数的性质: Jensen inequality: $0 \leq \theta \leq 1, \Rightarrow f(\theta x + (1-\theta)y) \leq \max\{f(x), f(y)\}$

Log-concave and log-convex function: A positive function f is log-concave if $\log f$ is concave: $f(\theta x + (1-\theta)y) \geq f(x)^\theta f(y)^{1-\theta}$ for $0 \leq \theta \leq 1$

例如 ① $f(x) = \frac{1}{\sqrt{(2\pi)^n \det \Sigma}} e^{-\frac{1}{2}(x-\bar{x})^T \Sigma^{-1}(x-\bar{x})}$ 是 log concave

② $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{u^2}{2}} du$

性质 integration: if $f: \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$ is log concave, then

$g(x) = \int f(x, y) dy$ is log concave

性质

$(\log f(x))'' \leq 0 \Rightarrow \left[\frac{1}{f(x)} f'(x) \right]' \leq 0 \Rightarrow -\frac{f'(x)}{f(x)^2} f'(x) + \frac{1}{f(x)} f''(x) \leq 0 \Rightarrow f(x) \nabla^2 f(x) \leq \nabla f(x) \nabla f(x)^T$

性质: f, g 是 log-concave 的, 那么 $(f * g)(x)$ 是 log-concave 的

其中 $(f * g)(x) = \int f(x-y) g(y) dy$ (卷积)

If $C \in \mathbb{R}^n$ convex, 而 y 是 pdf log-concave 的随机变量
 $f(x) = \text{prob}(x+y \in C)$ is log-concave (利用上一条性质证明)

实际意义: x 是生产产品参数, y 是生产时随机变量, C 是可接受的取值集合,
于是 $f(x)$ 是产量函数, 这就决定了 x 设置的范围

yield region: $\{x \mid f(x) \geq \alpha\}$ are convex

(证明: $\{x \mid \log f(x) \geq \log \alpha\}$ 而 $\log f(x)$ 是 concave, 其 superlevel set 是 convex 的)

Convexity with respect to generalized inequality k 是正交锥.

f is k convex if $\text{dom } f$ is convex and $f(\theta x + (1-\theta)y) \preceq_k \theta f(x) + (1-\theta)f(y)$

例: $f: S^m \rightarrow S^m$, $f(x) = x^2$ is S_+^m -convex (对称半正定矩阵)

想证 $\theta f(x) + (1-\theta)f(y) - f(\theta x + (1-\theta)y) \in S_+^m$

已知 $z^T x^2 z = \|xz\|_2^2$ 是 convex in x 的, $z^T [\theta x + (1-\theta)y]^2 z$

$$\leq \theta z^T x^2 z + (1-\theta) z^T y^2 z, \Rightarrow z^T [(\theta x + (1-\theta)y)^2 - \theta x^2 - (1-\theta)y^2] z \leq 0$$

$$\text{因此 } \theta x^2 + (1-\theta)y^2 - (\theta x + (1-\theta)y)^2 \in S_+^m$$

最优化问题标准形式

minimize $f_0(x)$

subject to $f_i(x) \leq 0 \quad i=1, \dots, m.$

$h_i(x) = 0 \quad i=1, \dots, p$

(implicit constrain: $x \in D$)

$$D = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=1}^p \text{dom } h_i$$

D is the domain of the problem

optimal, locally optimal

在一个范围内最优

凸优化标准形式

minimize $f_0(x)$

subject to $f_i(x) \leq 0 \quad i=1, \dots, m$

$a_i^T x = b_i \quad i=1, \dots, p$

(性质: 其 feasible set 也是凸的)

($f_0, \dots, f_m$ 是 convex 的)

如果 f_0 是拟凸的, 该问题为拟凸优化

两个问题等价, 解决一个就知道另一个如何解决

同理有 global / local optima. (local optima is global optima)

x is optimal iff x is feasible and $\nabla f_0(x)^T (y-x) \geq 0$, for all feasible y
 $\nabla f_0(x)$ 如果非负, 是 support hyperplane

Equality constrained: minimize $f_0(x)$, $Ax=b$

x is optimal iff exist v . $\nabla f_0(x) + Av = 0$, $x \in \text{dom} f_0$, $Ax=b$.

$$\begin{aligned} &\text{minimize } f_0(x) \\ &\text{s.t. } f_i(x) \leq 0 \quad i=1, \dots, m \\ &Ax=b \end{aligned}$$

$\Rightarrow$

$$\begin{aligned} &\text{minimize } f_0(Fz+x_0) \\ &\text{s.t. } f_i(Fz+x_0) \leq 0 \quad i=1, \dots, m \\ &\text{where } F \text{ and } x_0 \text{ 满足} \end{aligned}$$

$$Ax=b \Leftrightarrow x=Fz+x_0 \text{ for some } z$$

等价性, $z^* \Rightarrow Fz^* + x_0 = x^*$ 得到最优的 x .

不等式优化也有类似的等价问题, 主要是引入松弛变量


Epigraph form: $\text{minimize } f_0(x) \rightarrow \text{minimize } t \text{ s.t. } \underline{f_0(x) - t \leq 0}$

Quasiconvex optimization:

$\text{minimize } f_0(x)$

s.t. $f_i(x) \leq 0 \quad i=1, \dots, m$
 $Ax = b$

f_0 是拟凸的, $f_1, \dots, f_m$ 是凸的



如果 f 是拟凸的, 存在族函数 $\phi_t(x)$

固定 t 时 $\phi_t(x)$ 是 convex 的, f_0 的 t -sublevel set 是 ϕ_t 的 0-sublevel set

这样可以将问题转化为 convex feasible 的问题

$\text{minimize } t,$

s.t. $\phi_t(x) \leq 0, f_i(x) \leq 0 \quad Ax = b$

因此只需要二分查找, 代入值查看是否满足

将一个 piecewise-linear optimization 问题化为等价 LP 问题

$$\text{minimize } \max_{i=1, \dots, m} (a_i^T x + b_i) \iff \text{minimize } t$$
$$\text{s.t. } a_i^T x + b_i \leq t, \quad i=1, \dots, m$$

例: 多面体的切比雪夫中心 $P = \{x \mid a_i^T x \leq b_i, i=1, 2, \dots, m\}$ 的 Chebyshev center 是最大球球心, $B = \{x_c + u \mid \|u\|_2 \leq r\}$

$$a_i^T x \leq b_i \quad \forall x \in B \iff a_i^T x_c + r \|a_i\|_2 \leq b_i$$

因此优化问题可写为

$$\text{maximize } r$$

$$\text{s.t. } a_i^T x_c + r \|a_i\|_2 \leq b_i$$

线性分式规划

$$f_0(x) = \frac{c^T x + d}{e^T x + f} \quad \text{dom } f_0(x) = \{x \mid e^T x + f > 0\}$$


$$\begin{aligned} &\text{minimize } f_0(x) \\ &\text{s.t. } Gx \preceq h \\ &\quad Ax = b \end{aligned}$$

$$\begin{aligned} \text{LP} = & \text{minimize } c^T y + dz \\ & \text{s.t. } Gy \preceq hz \\ & \quad Ay = bz \\ & \quad e^T y + fz = 1 \\ & \quad z \geq 0 \end{aligned}$$

Quadratic Programming

$$\begin{aligned} &\text{minimize } \frac{1}{2} x^T P x + q^T x + r \\ &\text{s.t. } Gx \preceq h \\ & \quad Ax = b \end{aligned}$$

$P \in S_+^n$, 于是目标是一个凸二次函数.



例: 最小二乘:

$$\text{minimize } \|Ax - b\|_2^2$$

解析解: $x^* = A^+ b$ A^+ 是 A 的伪逆, 可添加线性约束

例 linear programming with random cost

$$\text{minimize } \bar{c}^T x + \gamma x^T \Sigma x = E C^T x + \gamma \text{var}(C^T x)$$

$$\text{s.t. } Gx \preceq h, \quad Ax = b$$

risk

Second-order cone programming

$$\text{minimize } f^T x$$

$$\text{s.t. } \|A_i x + b_i\|_2 \leq C_i^T x + d_i \quad i=1, \dots, m \quad (\text{second order cone})$$

$$A \in \mathbb{R}^{n \times n}, \quad F \in \mathbb{R}^{p \times n}$$

$n_i = 0$ 为 LP; $C_i = 0$ 为 QCQP

Robust LP $\Leftrightarrow$ SOCP

$$\text{minimize } C^T x$$

$$\text{s.t. } \text{prob}(a_i^T x \leq b) \leq \eta, i=1, \dots, m.$$

risk.



$$\exists x \text{ s.t. } \text{prob}(a_i^T x \leq b) = \Phi\left(\frac{b_i - a_i^T x}{\|\sum_{i=1}^m x\|_2}\right)$$

$$\text{其中 } \phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$$

$$\Leftrightarrow \text{minimize } C^T x$$

$$\text{s.t. } \bar{a}_i^T x + \Phi^{-1}(\eta) \|\sum_{i=1}^m x\|_2 \leq b_i, i=1, \dots, m$$

$$\exists \eta \text{ s.t. } \phi^{-1}(\eta) < 0 \quad \eta < \frac{1}{2}, \text{ 于是要求 } \eta \geq \frac{1}{2}$$

Geometric Programming

monomial function

$$f(x) = c x_1^{a_1} x_2^{a_2} \dots x_n^{a_n}$$

$$\text{dom } f = \mathbb{R}_{++}^n$$

$$c > 0, a_i \in \mathbb{R}$$

posynomial function: sum of monomials

$$f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} \dots x_n^{a_{nk}}$$

$$\text{dom } f \in \mathbb{R}_{++}^n$$

在 GP 中 $c > 0$!

Geometric programming

minimize $f_0(x)$

s.t. $f_i(x) \leq 1 \quad i=1, \dots, m$

$h_i(x) = 1 \quad i=1, \dots, p$

f_i 是 posynomial

h_i 是 monomial

将 GP 表达为 convex form:

$$y_i = \log x_i, \quad \log f(e^{y_1}, \dots, e^{y_n}) = a^T y + b$$

$$\text{对 } j \text{ posynomial } \log f(e^{y_1}, \dots, e^{y_n}) = \log \left(\sum_{k=1}^K e^{a_k^T y + b_k} \right) \quad (b_k = \log c_k)$$


于是 minimize $\log \left(\sum_{k=1}^K \exp(a_{0k}^T y + b_{0k}) \right)$

s.t. $\log \left[\sum_{k=1}^K \exp(a_{ik}^T y + b_{ik}) \right] \leq 0 \quad i=1, \dots, m$

$$Ay + d = 0$$

Vector optimization: $f_0(x) = (F_1(x), \dots, F_m(x))$

13) minimize (w.r.t $\mathbb{R}_+^2$) $(\|Ax-b\|_2^2, \|x\|_2^2)$
 optimal and Pareto-optimal (trade off)



Scalarization: minimize $\lambda^T f_0(x)$

if x is optimal for scalar problem, then it's Pareto-optimal for vector optimization problem.

例如: 带正则化项的最小二乘, 取 $\lambda = (1, \gamma)$, $\gamma > 0$


$$\text{minimize } \|Ax-b\|_2^2 + \gamma \|x\|_2^2$$

Duality

找到目标函数一个较好的下界

$$\begin{aligned} &\text{minimize } f_0(x) \\ &\text{s.t. } f_i(x) \leq 0 \\ &\quad h_i(x) = 0 \end{aligned} \quad \text{Lagrangian - } L: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}, \text{ dom } L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p$$

$$\Leftrightarrow L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \nu_i h_i(x)$$



$$\underline{f_0(x) + \lambda [f_1(x) \leq 0]}$$

λ 理解为如果超过约束, 要付出代价

Lagrangian Dual function: $g: \mathbb{R}^m \times \mathbb{R}^p \rightarrow \mathbb{R}$

$$g(\lambda, v) = \inf_{x \in D} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right)$$

g is concave, can be $-\infty$ for some λ, v

如果 $\lambda \geq 0$, 那么 $g(\lambda, v) \leq p^*$

proof $f_0(\tilde{x}) \geq L(\tilde{x}, \lambda, v) \geq \inf_{x \in D} L(x, \lambda, v) = g(\lambda, v)$
 $\tilde{x}$ is feasible

一个例子 线性规划.

$$\begin{aligned} \min_x & C^T x \\ \text{s.t.} & Ax = b, Gx \leq h \end{aligned} \Rightarrow \begin{cases} u^T Ax = u^T b \\ -v^T Gx \geq -v^T h, v \geq 0. \end{cases}$$

希望构造出 $C^T x$ 的形式

$(-A^T u - G^T v)^T x \geq -b^T u - h^T v$ 与 $C^T x \geq m$ 对应. 找到下界

其对偶问题为 $\max_{u,v} -b^T u - h^T v$
 $\text{s.t. } -A^T u - G^T v = C, v \geq 0$

如果使用 lagrangian function $L(x, u, v) = C^T x + u^T (Ax - b) + v^T (Gx - h)$

$$g(u, v) = \min_x L(x, u, v) = \begin{cases} -b^T u - h^T v & C = -A^T u - G^T v \\ -\infty & \text{otherwise} \end{cases}$$

例: 证明最大流和最小割问题存在对偶关系

例. matrix game.

$$\begin{aligned} \min_{x,t} & t \\ \text{s.t.} & x \geq 0, 1^T x = 1; P^T x \leq t \end{aligned} \Rightarrow g(u, v, y) = \begin{cases} v & 1 - 1^T y = 0, Py - u - v = 0 \\ -\infty & \text{otherwise} \end{cases} \Rightarrow \begin{aligned} & \max_{y,v} v \\ & \text{s.t. } y \geq 0, 1^T y = 1, Py \geq v \end{aligned}$$

例)
$$\begin{array}{ll} \text{minimize} & \|x\| \\ \text{s.t.} & x \geq 0 \end{array}$$

在共轭函数中 $\inf_x (\|x\| - y^T x) = 0$ if $\|y\|_* \leq 1$, 否则 $\inf_x (\|x\| - y^T x) = -\infty$
 所以 lower bound property: $p^* \geq 0$ if $\|y\|_* \leq 1$

例) two-way partition: (non convex problem, W 是对称的即可)
 W_{ij} 是把 i 与 j 分成一组的 cost

$$\begin{array}{ll} \text{minimize} & x^T W x \\ \text{s.t.} & x_i^2 = 1 \quad i = 1, \dots, n \end{array}$$

dual function
$$\begin{aligned} g(v) &= \inf_x [x^T W x + \sum_i v_i (x_i^2 - 1)] = \inf_x x^T W x + x^T \text{diag}(v) x - 1^T v \\ &= \inf_x x^T (W + \text{diag}(v)) x - 1^T v = \begin{cases} -1^T v & W + \text{diag}(v) \geq 0 \\ -\infty & \text{otherwise} \end{cases} \end{aligned}$$

求解时得到 W 最小特征值的特征向量

拉格朗日对偶与共轭函数的关系

minimize $f_0(x)$
s.t. $Ax \preceq b, Cx = d \Rightarrow$ dual function: $g(\lambda, v) = \inf [f_0(x) + (A^T \lambda + C^T v)x - b^T \lambda - d^T v]$

$$\Rightarrow g(\lambda, v) = -f_0^*(-A^T \lambda - C^T v) - b^T \lambda - d^T v$$

如果已知 $f_0^*(x)$ 就会比较简单

例如 $f_0(x) = \sum x_i \log x_i$ $f_0^*(y) = \sum e^{y_i - 1}$

强对偶和弱对偶

weak duality: $P^* \geq d^*$ (P^* 是原问题最优值)

(always holds) 例如 Semi Definite Problem

strong duality: $P^* = d^*$ zero duality gap

(holds for convex problems)

Slater's condition: $P^* = d^*$ if $\exists \tilde{x}, A\tilde{x} < b$, 对于 $P: Ax \preceq b$ 的约束

(等式约束满足, 非仿射的不等式约束不取等, 则具备强对偶性)

对偶问题的几何理解：简化问题为 $\min f_0(x)$
st. $f_i(x) \leq 0$

$$G = \{(f_i(x), f_0(x)) \mid x \in D\} \quad (\text{几何区域})$$

$$f_0(x) = \inf \{t \mid (u, t) \in G, u \leq 0\}$$

$$g(\lambda) = \inf \{\lambda u + t \mid (u, t) \in G\}$$


原问题的最优值对应平行于 x 轴的直线

对于 $\lambda u + t$, $\lambda \geq 0 \rightarrow$ 斜率非正, $g(\lambda)$ 是过 (u, t) 的直线绕 (u, t) 一个圈后与 y 轴交点最小值
很多情况下为 $-\infty$; 如果固定 λ , 如果只切一边, 可以上移直线, 对偶函数值会更大, 所以
不可能为最优值; 如果相交, 可以下移, 得到更小的 $g(\lambda)$, 最终黄线体现了 λ .

对偶问题鞍点视角: saddle point: 对函数 $L(x, \lambda)$ 如果满足

$$\inf_{x \in D} \sup_{\lambda \geq 0} L(x, \lambda) = \sup_{\lambda \geq 0} \inf_{x \in D} L(x, \lambda), \text{ 且取到极值点 } (x^*, \lambda^*) \text{ 相同, 称该点为鞍点.}$$

如果满足 strong duality, Lagrangian function 一定存在鞍点.



Complementary slackness: Assume strong duality holds, x^* is primal optimal, (λ^*, ν^*) is dual optimal

$$f_0(x^*) = g(\lambda^*, \nu^*) \leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p \nu_i^* h_i(x^*) \leq f_0(x^*)$$

结论 (1) x^* 最小化 $L(x, \lambda^*, \nu^*)$

$$(2) \quad \lambda_i^* f_i(x^*) = 0 \quad \left\{ \begin{array}{l} \lambda_i^* > 0 \Rightarrow f_i(x^*) = 0 \\ f_i(x^*) < 0 \Rightarrow \lambda_i^* = 0 \end{array} \right.$$

Karush-Kuhn-Tucker conditions:

1. primal constraints $f_i(x) \leq 0$, $h_i(x) = 0$
2. dual constraints $\lambda \geq 0$
3. complementary slackness $\lambda_i f_i(x) = 0$
4. $\nabla_x L(x, \lambda, \nu) = 0$

如果满足 strong duality, 并且 x^*, ν^*, λ^* 是最优的, 则 KKT 条件一定成立.

反之, 如果 x^*, ν^*, λ^* 满足 KKT, 则对应为最优解

对偶范数 Dual Norm: $\|x\|_* = \max_{\|z\| \leq 1} z^T x$

性质 1. $\|x\|_{**} = \|x\|$

证明 $\min_y \|y\|$, s.t. $x=y$, $L(y,u) = \|y\| + u^T(x-y) = \|y\| - y^T u + x^T u$

如果 $\|u\|_* > 1$, 则 $\max_{\|z\| \leq 1} z^T u > 1$, $\exists y$ 使 $\|y\| - y^T u < 0$, 于是 $\min_y \{ \|y\| - y^T u \} = -\infty$

如果 $\|u\|_* \leq 1$ 则 $\|y\| \geq y^T u$, $\min_y \{ \|y\| - y^T u \} = 0$

于是 dual problem 为 $\max_u u^T x$, s.t. $\|u\|_* \leq 1$, 其实解就是 $\|x\|_{**}$ $\square$

共轭函数性质:

① Fenchel's Inequality $\forall x, y$ 都有 $f(x) + f^*(y) \geq x^T y$

② $f^{**} \leq f$; 如果 f 是闭的且凸的, 那么 $f^{**} = f$

例: 证明 $f(x) = \|x\|$ 的共轭函数为 $f^*(y) = I_{\{z: \|z\|_* \leq 1\}}(y)$

设 $h(x) = I_C(x)$, 则 $h^*(y) = \max_x (y^T x - h(x)) = \max_{x \in C} y^T x$

当 C 是 convex set 时, $h^{**} = h$; 示性函数共轭是其本身

同时 $\|x\| = \|x\|_{**} = \max_{\|z\|_* \leq 1} z^T x$, 恰好为示性函数的共轭再共轭一遍即可 $\square$

例 LASSO Dual: 设 $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times p}$, 考虑 $\min_{\beta} \frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1$,

解. 添加人工约束 $\min_{\beta, z} \frac{1}{2} \|y - z\|_2^2 + \lambda \|\beta\|_1$, s.t. $z = X\beta$

$g(u) = \min_{\beta} \lambda \|\beta\|_1 - u^T X\beta + \min_z \frac{1}{2} \|y - z\|_2^2 + u^T z$, 关于 β 的 min 不易求.

其中 $\min_{\beta} \lambda \|\beta\|_1 - u^T X\beta = -\lambda \max_{\beta} \left(\frac{u^T X}{\lambda} \beta - \|\beta\|_1 \right) = -\lambda h^* \left(\frac{u^T X}{\lambda} \right)$

其中 $h(x) = \|\beta\|_1$, 由之前结论 $h(x)$ 的共轭函数为 $h^*(y) = \mathbb{I}_{\{z: \|z\|_{\infty} \leq 1\}}(y)$,
 $-\lambda \mathbb{I}_{\{v: \|v\|_{\infty} \leq 1\}} \left(\frac{X^T u}{\lambda} \right)$

又 $\nabla_z \left(\frac{1}{2} \|y - z\|_2^2 + u^T z \right) = z - y + u = 0 \Rightarrow z = y - u$; $\min_z \frac{1}{2} \|y - z\|_2^2 + u^T z = u^T y - \frac{1}{2} \|u\|_2^2$

于是 Dual problem 为 $\max_u \frac{1}{2} (\|y\|_2^2 - \|y - u\|_2^2)$, s.t. $\|X^T u\|_{\infty} \leq \lambda$

$\Rightarrow \min_u \|y - u\|_2^2$, s.t. $\|X^T u\|_{\infty} \leq \lambda$; 由于无不等式约束, 有 strong duality

由 KKT, $u = y - X\beta$, 由投影算子, $\|u - u'\| \leq \|y - y'\|$, LASSO 可以减小数据扰动的影响

例 $\min_x f(x) + g(x) \Rightarrow \min_{x, z} f(x) + g(z)$, s.t. $x = z$. (近端梯度法)

于是 $g(u) = \min_{x, z} f(x) + g(z) + u^T (x - z) = -\max_x [u^T x - f(x)] - \max_z [-u^T z - g(z)]$

提 $g(u) = -f^*(u) - g^*(-u)$

Theorem: 对一般优化问题

$$\min f_0(x)$$

$$\text{s.t. } f_i(x) \leq 0$$

$$h_i(x) = 0$$

$$i = 1, \dots, m$$

$$i = 1, \dots, p$$

如果 $f_0, f_1, \dots, f_m$ 都是闭的且凸的, $h_1, \dots, h_p$ 是 affine, 则 对偶函数的对偶函数仍然是原函数

Perturbed problem and its dual

$$(P) \min f_0(x)$$

$$\text{s.t. } f_i(x) \leq u_i \quad i=1, \dots, m$$

$$h_i(x) = v_i \quad i=1, \dots, p$$

$$(D) \max g(\lambda, v) - u^T \lambda - v^T v$$

$$\text{s.t. } \lambda \geq 0$$

$$(\text{假设 } p(x^*) = g(\lambda^*, v^*))$$

关注 $P^*(u, v)$

global sensitivity results: 根据 weak duality: $P^*(u, v) \geq g(\lambda^*, v^*) - u^T \lambda^* - v^T v^*$


① λ_i^* 较大, 收紧约束 $u_i < 0$, P^* 会更大

$$= P^*(0, 0) - u^T \lambda^* - v^T v^*$$

λ_i^* 较小, 放松约束, $u_i > 0$, P^* 不会减小太多


② $v_i^* > 0$ 且较大, $v_i < 0$ 使 P^* 显著增大

③ $v_i^* > 0$ 且较小, $v_i > 0$ 并不会使 P^* 减小太多



local sensitivity: 假设 $p^*(u, v)$ 在 $(0, 0)$ 可导

then $\lambda_i^* = \frac{\partial p^*(0, 0)}{\partial u_i}$, $\nu_i^* = \frac{\partial p^*(0, 0)}{\partial v_i}$ (刻画了拉格朗日乘数与 perturbation 的关系)



利用变量替换求对偶:

minimize $f_0(Ax+b)$

dual function constrain

$\Rightarrow$ minimize $f_0(y)$
s.t. $Ax+b-y=0$

$\rightarrow$ (D)

$$g = \inf_x L(x) = \inf_x f_0(Ax+b) = p^*$$

$$\text{maximize } b^T \nu - f_0^*(\nu)$$

$$\text{s.t. } A^T \nu = 0$$

$$g(\nu) = \inf_{x, y} [f_0(y) - \nu^T y + \nu^T Ax + \nu^T b] = -f_0^*(\nu) + \nu^T b + \inf_x \nu^T Ax = \begin{cases} b^T \nu - f_0^*(\nu) & A^T \nu = 0 \\ -\infty & \text{otherwise} \end{cases}$$

例 minimize $C^T x$
s.t. $Ax = b$
 $-1 \leq x \leq 1$

reformulation minimize $f_0(x) = \begin{cases} C^T x & -1 \leq x \leq 1 \\ \infty & \text{otherwise} \end{cases}$

dual function $g(v) = \inf_{-1 \leq x \leq 1} [C^T x + v^T (Ax - b)] = \underline{-v^T b - \|A^T v + C\|_1}$

这里的 constrain 变成隐式的

feasible problem:

minimize 0
s.t. $f_i(x) \leq 0$
 $h_i(x) = 0$

由于 $d^* \leq p^*$ 始终成立, 若 $d^* > 0$,
说明是 infeasible 的

更一般的对偶: 对于 general inequality constrain $f_i(x) \preceq_{K_i} 0$
目标 $\lambda_i^T f_i(x)$ $\lambda_i \in R^{k_i}$

例 SDP minimize $C^T x$
s.t. $x_1 F_1 + \dots + x_n F_n \preceq G$ (引入矩阵形式的拉格朗日乘子 $Z \in S^k$)
($F_i, G \in S^k$)

$L(x, Z) = C^T x + \text{tr}(Z(x_1 F_1 + \dots + x_n F_n - G))$

$$p(Z) = -\text{tr}(ZG) + \inf_x x^T \left[c^T + \begin{pmatrix} \text{tr}(F_1 Z) \\ \vdots \\ \text{tr}(F_n Z) \end{pmatrix} \right] = \begin{cases} -\text{tr}(ZG) & \text{tr}(F_i Z) + C_i = 0 \\ -\infty, & \text{otherwise} \end{cases}$$

是 dual SDP

$$\text{maximize } -\text{tr}(ZG)$$

$$\text{s.t. } Z \succeq 0, \text{tr}(F_i Z) + C_i = 0, \quad i=1, 2, \dots, n.$$

如果 SDP 严格满足 ($\exists x$ 使 $x_1 F_1 + \dots + x_n F_n \prec G$), 则 $p^* = d^*$

(因为满足 strong duality)

Approximation and fitting

对于 norm approximation. $\|Ax - b\|$

penalty function approximation

$$\text{minimize } \phi(r_1) + \dots + \phi(r_m)$$

$$\text{s.t. } r = Ax - b$$

$\phi(u) = u^2$, $\phi(u) = \max\{0, |u| - a\}$ ϕ 有不同的设计方式

进而实现不同的优化效果.

梯度与次梯度

二阶项的近似项

$$x^{(k)} = x^{(k-1)} - t_k \cdot \nabla f(x^{(k-1)})$$

下面辅助理解

$$\text{由于 } f(y) \approx f(x) + \nabla f(x)^T (y-x) + \frac{1}{2t} \|y-x\|^2 = g(y)$$

$$\nabla g(y) = \nabla f(x) + \frac{1}{t} y - \frac{1}{t} x = 0 \Rightarrow y = x - t \nabla f(x)$$

Theorem 1. 设 $f(x)$ 有 smoothness, $t \leq \frac{1}{L}$, 则

$$\min_{i=0, \dots, k} \|\nabla f(x^{(i)})\| \leq \sqrt{\frac{2(f(x^{(0)}) - f(x^*))}{t(k+1)}}, \text{ 其中 } f(x^*) \text{ 表示最小值}$$

结论: 固定步长可以收敛, 但步长不能太大

Theorem 2: 在 theorem 1 基础上, 若添加 f 为凸.

$$\text{有 } f(x^{(k)}) - f(x^*) \leq \frac{\|x^{(0)} - x^*\|^2}{2k}, \text{ (说明如果 } t \leq \frac{1}{L}, \text{ 得到 } O(\frac{1}{k}) \text{ 收敛速度)}$$

次梯度 (subgradient): 对于 凸 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 和向量 $g \in \mathbb{R}^n$, 如果对于任意的 y , 都有 $f(y) \geq f(x) + g^T (y-x)$, 那么称 g 为 f 在 x 点的次梯度.

如果 x 处函数可导, 那么次梯度唯一, 就是 $\nabla f(x)$

次微分: 定义 $\partial f(x)$ 为所有 x 点处 f 的次梯度集合, 称为次微分

类似的, 有次梯度下降方法

案例: LASSO: $\min_{\beta} \frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1, \lambda \geq 0$

由于 $\|\beta\|_1$ 是非光滑项, 考虑次梯度, 计算次微分

$$0 \in \partial \left(\frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right) = -X^T(y - X\beta) + \lambda \partial \|\beta\|_1$$

$$\Rightarrow X^T(y - X\beta) = \lambda v, \text{ 其中 } v_i \in \begin{cases} \{1\} & \beta_i > 0 \\ \{-1\} & \beta_i < 0 \\ [-1, 1] & \beta_i = 0 \end{cases} \quad i = 1, \dots, p$$

直观理解: 如果某个特征与估计值的残差关系不大, 尽可能将 β 这一分量置为 0

动量方法:

Polyak Heavy-Ball Method: 梯度方法迭代公式 $x_{k+1} = x_k - \alpha_k \nabla f(x_k)$

此时为 $x_{k+1} = x_k - \alpha_k \nabla f(x_k) + \beta_k (x_k - x_{k-1})$

(直观理解: 到达局部极小值不立即停下)

Conjugate Gradient: 只使用一阶信息, 没有直接使用梯度, 不属于加速梯度方法. (略)

加速梯度方法: Nesterov 给梯度内添加动量项

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k + \beta_k(x_k - x_{k-1})) + \beta_k(x_k - x_{k-1})$$

随机梯度下降法: 解决问题, $\min_x \frac{1}{m} \sum_{i=1}^m f_i(x)$

为了不计算每个函数值, 每次迭代使用不同的分量函数, 但是选取时概率分布应该均匀
因为随机梯度法在接近最小值时, 一般不易收敛, 所以要减小步长

mini batch GD: $x^{(k)} = x^{(k-1)} - t_k \cdot \frac{1}{b} \sum_{i \in I_k} \nabla f_i(x^{(k-1)})$, $I_k \subset \{1, \dots, m\}$, $|I_k| = b \ll m$

希望 $E[\frac{1}{b} \sum_{i \in I_k} \nabla f_i(x)] = \nabla f(x)$

近端梯度法: 只关心 $f(x) = g(x) + h(x)$, $g(x)$ 凸和可微, $h(x)$ 凸, 可以不光滑

$(x^+ = x - t \nabla f(x))$, 设 $\bar{f}_t(x) = f(x) + \nabla f(x)^T (z - x) + \frac{1}{2t} \|z - x\|_2^2$

$$x^+ = \arg \min_z \bar{g}_t(z) + h(z) = \arg \min_z \frac{1}{2t} \|z - (x - t \nabla g(x))\|_2^2 + h(z)$$

一方面要求 z 与 x 梯度下降更新结果接近, 另一方面要求 $h(z)$ 尽可能小.

定义 $\text{prox}_{h,t}(x) = \arg\min_z \frac{1}{2t} \|x-z\|^2 + h(z)$ 为 近端算子. (极小值是唯一的)

$$x^{(k)} = \text{prox}_{h,t_k}(x^{(k-1)} - t_k \nabla g(x^{(k-1)}))$$

定义 $G_t(x) = \frac{x - \text{prox}(x - t \nabla g(x))}{t}$, 于是 $x^{(k)} = x^{(k-1)} - t_k G_{t_k}(x^{(k-1)})$

步长选取: 回溯法: 设置初始步长, 每一步只要满足

$$g(x - t G_t(x)) \geq g(x) - t \nabla g(x)^T G_t(x) + \frac{t}{2} \|G_t(x)\|_2^2, \text{ 则 } t = \beta t. \text{ (缩放)}$$

每一步的近端算子不同

缺陷: 不一定能算出 prox 映射出的解和解

在 x 处一阶泰勒展开

牛顿法: 根据估计 $0 = \nabla f(x+v) \simeq \nabla f(x) + \nabla^2 f(x)v$, v 代表步长, 希望在 $x+v$ 得到驻点

$$\text{有 } \nabla f(x) + \nabla^2 f(x)(y-x) = 0 \Rightarrow y-x = -\nabla^2 f(x)^{-1} \nabla f(x)$$

$$\Rightarrow x^+ = x - \nabla^2 f(x)^{-1} \nabla f(x) \quad (\text{隐含 } \nabla f(y) = 0)$$

要求优化公式满足 $x^+ = \arg\min_y f(x) + \nabla f(x)^T(y-x) + \frac{1}{2}(y-x)^T \nabla^2 f(x)(y-x)$

牛顿法相对于梯度方法对二阶项有更加精确的估计. (相比于 $\frac{1}{2t} \|y-x\|_2^2$)

通过收敛性分析, 对于一个强凸函数, 牛顿法一定收敛.

内点法: 屏障法:

$$\min_x f(x)$$

$$\text{s.t. } h_i(x) \leq 0, i=1, \dots, m. Ax=b$$

希望 f, h_i 都是凸函数且二阶可导. 问题具备强对偶性, 转化为无约束问题

$$\min_x f(x) + \sum_{i=1}^m I_{\{h_i(x) \leq 0\}}(x)$$

找到一个函数, 将示性函数化为一个近似但性质更好的函数 $\frac{\log(-h_i(x))}{t}$

称 $\phi(x) = -\sum_{i=1}^m \log(-h_i(x))$ 为 log-barrier function.

中心路径: 一个 t 对应一个解, t 连续变化, 解也会连续变化, 形成的弧线

$$\text{例: } \min_x t f(x) + \phi(x) \quad \text{s.t. } Ax=b \quad \text{KKT condition: } \begin{cases} t \nabla f(x^*(t)) - \sum_{i=1}^m \frac{1}{h_i(x^*(t))} \nabla h_i(x^*(t)) + A^T w = 0 \\ Ax^*(t) = b \\ h_i(x^*(t)) < 0 \quad i=1, \dots, m \end{cases}$$

希望通过变换, 使屏障法的对偶问题的最优解是原问题对偶问题最优解

令 $u_i^*(t) = \frac{-1}{t h_i(x^*(t))}, i=1, \dots, m. v^*(t) = \frac{w}{t}$, 那么 u^*, v^* 是原问题对偶问题最优解

$$\text{证明 } L(x, u, v) = f(x) + \sum_{i=1}^m h_i(x) u_i + v^T (Ax - b)$$

① 说明 u^*, v^* 为 dual problem 的可行解. 由于 $h_i(x) < 0$, 有 $u^* > 0$

② 代入 u^*, v^* 得到 $\nabla L(x^*, u^*, v^*) = 0$ □

由于 $g(u^*(t), v^*(t)) = f(x^*(t)) - \frac{m}{t}$, 对偶间隔不超过 $\frac{m}{t}$. 当 $t \rightarrow +\infty, x^*(t) \rightarrow x^*$

原始-对偶方法 (primal-dual method)

扰动KKT条件,

$$\begin{cases} \nabla f(x) + \sum_{i=1}^m u_i \nabla h_i(x) + A^T v = 0 \\ \underline{u_i h_i(x) = -\frac{1}{t}}, i=1, \dots, m \\ h_i(x) \leq 0, i=1, \dots, m \\ Ax = b \end{cases}$$

$$\Rightarrow r(x, u, v) =$$

目标

$$\begin{bmatrix} \nabla f(x) + \sum_{i=1}^m u_i \nabla h_i(x) + A^T v \\ -\text{diag}(u)h(x) - \frac{1}{t} \\ Ax - b \end{bmatrix} = 0$$

严格可行域内部

使用牛顿法 $r(z + \Delta z) \approx r(z) + J_r(z) \Delta z = 0$, 接下来逐块计算 $J_r(z)$

$\Rightarrow$

r_{dual} 分别对 x, u, v 求导, 得到矩阵第一行

$$\begin{bmatrix} H_{\text{pd}}(x) & Dh(x)^T & A^T \\ -\text{diag}(u) Dh(x) & -\text{diag}(h(x)) & 0 \\ A & 0 & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta u \\ \Delta v \end{bmatrix} = - \begin{bmatrix} r_{\text{dual}} \\ r_{\text{cent}} \\ r_{\text{prim}} \end{bmatrix}$$

$$H_{\text{pd}} = \nabla^2 f(x) + \sum_{i=1}^m u_i \nabla^2 h_i(x)$$

$r_{\text{dual}} = 0$ 说明 u, v 是对偶问题的可行解, 但是不一定可行, 所以引入代理-对偶间隔
相比对 barrier method, 放松"可行"的限制

牛顿步同时更新 x, u, v . (如果直接对 $u_i h_i(x) = 0$ 做牛顿法, Jacobian 在边界奇异)

近端牛顿法: 使用近端算子求解特定非光滑问题的二阶方法

在近端梯度法中, $x^+ = \arg\min_z \bar{g}_t(z) + h(z) = \arg\min_z \frac{1}{2t} \|z - (x - t \nabla g(x))\|_2^2 + h(z)$

设 $v = z - x$, 方向向量, 则 $v^+ = \arg\min_v \nabla g(x)^T v + \frac{1}{2t} \|v\|_2^2 + h(x+v)$

利用牛顿法思想 $v^+ = \arg\min_v \nabla g(x^{(k-1)})^T v + \frac{1}{2} v^T H^{(k-1)} v + h(x^{(k-1)} + v)$

$x^{(k)} = x^{(k-1)} + t_k v^{(k)}$, 其中 $H^{(k-1)} = \nabla^2 g(x^{(k-1)})$

这与 $x^+ = \arg\min_z \frac{1}{2} \|x - H^{-1} \nabla g(x) - z\|_H^2 + h(z)$, $\|x\|_H^2 = x^T H x$

定义 $\text{prox}_H(x) = \arg\min_z \frac{1}{2} \|x - z\|_H^2 + h(z)$

$z^{(k)} = \text{prox}_{H^{(k-1)}}(x^{(k-1)} - (H^{(k-1)})^{-1} \nabla g(x^{(k-1)}))$

$x^{(k)} = x^{(k-1)} + t_k (z^{(k)} - x^{(k-1)})$;

步长选取时仍然采用回溯法, 性质分析和收敛性分析略

矩阵论/数值线性代数. (分析矩阵运算复杂度)

浮点运算, (如果为0不参与运算). 对上、下三角矩阵有特点的优化方法, 从而降低时间复杂度.

$Ax=b$ 对一般的 A 使用高斯消元法, 复杂度为 $O(n^3)$

灵敏度分析, $(A + \varepsilon F)x(\varepsilon) = (b + \varepsilon f)$, 作扰动后, 求解的误差

坐标下降法: 如果函数在每个维度达到极小值, 能否保证函数找到极小

值点: $f(x) = g(x) + \sum_{i=1}^n h_i(x)$, g 凸并且光滑, h_i 是凸函数.

$$f(y) - f(x) \geq \nabla g(x)^T (y - x) + \sum [h_i(y_i) - h_i(x_i)]$$

由于 $0 \in \nabla_i g(x) + \partial h_i(x_i)$, 则 $-\nabla_i g(x)$ 为 $h_i(x_i)$ 的次梯度

$$\text{于是 } h_i(y_i) \geq h_i(x_i) - \nabla_i g(x)^T (y_i - x_i)$$

$$\Rightarrow f(y) - f(x) \geq 0$$

$$\text{因此 } x_i^{(k)} = \arg \min_{x_i} f(x_1^{(k)}, \dots, x_{i-1}^{(k)}, x_i, x_{i+1}^{(k-1)}, \dots, x_n^{(k-1)})$$

一定要保证一轮不重复地遍历完每个维度

例: SVM dual. 给定 $y \in \{-1, 1\}^n$, $X \in \mathbb{R}^{n \times p}$, 对问题 $\min_{\beta, \beta_0, \xi} \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i$

s.t. $\xi_i \geq 0, i=1, \dots, n$, $y_i (x_i^T (\beta + \beta_0)) \geq 1 - \xi_i$; 如果 $\tilde{X} = \text{diag}(y) X$, 那么 dual problem

为 $\min_{\alpha} \frac{1}{2} \alpha^T \tilde{X} \tilde{X}^T \alpha - 1^T \alpha$, s.t. $0 \leq \alpha \leq C$, $\alpha^T y = 0$. 考虑求解此对偶问题的算法

$$L(\beta, \beta_0, \xi, u, v) = \frac{1}{2} \|\beta\|_2^2 + C \sum \xi_i - u^T \xi + \sum \alpha_i [1 - \xi_i - y_i (x_i^T \beta + \beta_0)]$$

$$\nabla_{\beta} L = \beta - \sum \alpha_i y_i x_i = 0 \Rightarrow \beta = \tilde{X}^T \alpha$$

采用 Sequential Minimal Optimization.

该问题的互补松弛条件为 $\alpha_i (1 - \xi_i - (\tilde{X}\beta)_i - y_i \beta_0) = 0, i=1, \dots, n.$

$$(C - \alpha_i) \xi_i = 0, i=1, \dots, n \rightarrow \text{满足 Slater 条件}$$

由于该问题满足 strong duality, 只要约束满足, 就可以认为找到极小值和极小值点。优化时, 每次挑选不满足互补松弛条件的两个变量 α_i, α_j , 然后固定其他变量为常数, 把问题变成坐标下降法。

此外 coordinate descent 可以引伸出 coordinate gradient descent.

对偶上升法 (Dual Ascent): 对原问题求对偶, 得到极大值问题.

$$(P) \min_x f(x) \quad \Rightarrow \quad (D) \max_u -f^*(-A^T u) - b^T u$$

s.t. $Ax=b$

设 $g(u) = -f^*(-A^T u) - b^T u$, 有 $\partial g(u) = A \partial f^*(-A^T u) - b$

由于 $f^*(-A^T u) = \sup_z (z^T(-A^T u) - f(z)) = \sup_z (-z^T A^T u - f(z))$

如果 $x \in \partial f^*(-A^T u)$, 则 $x \in \arg \min_z f(z) + u^T A z$

给定 u , 找到 x' , $\partial g(u) = A x' - b$

于是 $x^{(k)} \in \arg \min_x f(x) + (u^{(k-1)})^T A x$; $u^{(k)} = u^{(k-1)} + t_k (A x^{(k)} - b)$

说明我们并不需要知道对偶问题的具体形式, 就可以使用对偶上升法。

交替方向乘子法 ADMM: Alternating Direction Method of Multipliers

关注的问题

$$\min_x f(x) + g(z), \quad \text{s.t.} \quad Ax + Bz = c$$

使用增强拉格朗日法, 再使用对偶上升法的迭代公式

$$\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + u^T (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|_2^2$$

ADMM 的更新公式为:

$$x^{(k)} = \arg \min_x L_p(x, z^{(k-1)}, u^{(k-1)})$$

$$z^{(k)} = \arg \min_z L_p(x^{(k)}, z, u^{(k-1)})$$

$$u^{(k)} = u^{(k-1)} + \rho(Ax^{(k)} + Bz^{(k)} - c)$$

scaled form ADMM:

当我们设 $w = \frac{u}{\rho}$, 有 $L_p(x, z, w) = f(x) + g(z) + \frac{\rho}{2} \|Ax + Bz - c + w\|_2^2 - \frac{\rho}{2} \|w\|_2^2$

例 LASSO: $\min_{\beta} \frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1$ 的 ADMM 解法

将问题写为 $\min_{\beta, \alpha} \frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\alpha\|_1, \text{ s.t. } \beta - \alpha = 0$

则拉格朗日函数为 $L_p = \frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\alpha\|_1 + \frac{\rho}{2} \|\beta - \alpha + w\|_2^2 - \frac{\rho}{2} \|w\|_2^2$

第1步: 优化 β . $\min_{\beta} \frac{1}{2} \|y - X\beta\|_2^2 + \frac{\rho}{2} \|\beta - \alpha + w\|_2^2$

$$= \min_{\beta} \frac{1}{2} \beta^T X^T X \beta - y^T X \beta + \frac{\rho}{2} \beta^T \beta - \rho(\alpha - w)^T \beta$$

对 β 求梯度 $(X^T X + \rho I) \beta - X^T y - \rho(\alpha - w) = 0$

$$\beta^{(k)} = (X^T X + \rho I)^{-1} (X^T y + \rho \alpha^{(k-1)} - \rho w^{(k-1)})$$

第2步: 优化 α . $\min_{\alpha} \lambda \|\alpha\|_1 + \frac{\rho}{2} \|\beta - \alpha + \omega\|_2^2$

$$\alpha^{(k)} = S_{\frac{\lambda}{\rho}}(\beta^{(k)} + \omega^{(k-1)})$$

$$\omega^{(k)} = \omega^{(k-1)} + \beta^{(k)} - \alpha^{(k)}$$

发现 ADMM 迭代速度没有特别快.