


# 作业报告 (Week 1)

毛川 2300013218

## 多臂老虎机

分别实现了： $\epsilon$ -greedy策略、UCB策略、Gradient Bandit策略、优化初值策略。代码见 多臂老虎机/bandit.py。

## 实验结果：



## 结果分析：

- $\epsilon$ -greedy策略：
  - 在实验中， $\epsilon = 0.1/0.2$ 前期 reward 增长快，作为较大的 $\epsilon$ ，前期更容易找到较优策略。但是  $\epsilon = 0.2$  在策略收敛时 average reward 最低，因为当所有的策略都确定了最优的 bandit 后，该策略仍然以一定的概率选择一个次优的 bandit。
  - 在该图中  $\epsilon = 0.01$  的策略在前期增长最慢，但是次优性这是由随机性导致的， $\epsilon = 0.01$ 过于保守，探索不足，如果最初探索的老虎机是次优的，则很难跳出局部最优解。
  - 当执行足够多的迭代次数，且 bandit 的 reward 保持不变时， $\epsilon$ -较小策略最终收敛时的 average reward 更大。

- UCB 策略：

- $$A_t = \arg \max_a \left[ Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

- 当参数  $c$  较大时( $c=10$ )，策略前期增长较慢，UCB 策略在前期增长较慢，因为该策略在前期会尝试所有的 bandit，探索性较强。
  - 但是当执行较多的迭代次数后，UCB 主要关注第一项，同时图中由于老虎机的数目少，不同参数的策略均找到了最优的 bandit。所以都有较高的 average reward。

- Gradient Bandit 策略：

- $$\pi_t(a) = \frac{e^{H_t(a)}}{\sum_b e^{H_t(b)}}$$

- $$H_{t+1}(A_t) = H_t(A_t) + \alpha(R_t - \bar{R}_t)(1 - \pi_t(A_t))$$

- $$H_{t+1}(a) = H_t(a) - \alpha(R_t - \bar{R}_t)\pi_t(a), a \neq A_t$$

- $\alpha$  较大时，初期的 reward 增长快，因为每次探索到较优的 bandit 后，概率提升较大。反之同理。
  - 但是  $\alpha$  较大时，收敛时策略的 average reward 较低，观察图中， $\alpha = 1$  并没有找到最优的 bandit，说明该策略过于激进，容易陷入局部最优解。
- 优化初值策略：
  - 该算法不同参数的随机性较大。当初值更加乐观时，策略会探索更多的 bandit，从而更可能在前期找到最优的 bandit。
  - 如果 init\_value 较小，则策略会过早地收敛到一个次优的 bandit 上，导致 average reward 较低。

## tictactoe

实现了基于  $\epsilon$ -Greedy 和随机策略两个的训练算法，执行多轮训练，每轮完成一局游戏，如果胜利 reward 为 1，失败为 -1，平局为 0。回溯更新储存的 Value function。

## 实现细节

- 转态编码：由于只有 9 个格子，每个格子有 3 种状态（空、X、O），所以可以用一个 18 位的二进制数来编码当前的状态。将每个 18 位的二进制数映射为一个 value。
- 棋局过程存储，由于要在己方决策时的每个 state 储存值函数，使用一个 stack 来储存一次 game 的所有 state。
- 由于 rand() 生成的随机数不够随机，使用 C++11 的 <random> 库来生成随机数。

## 实验结果

- 由于对手采取所有可行区域的第一个 action，策略非常固定，所以无论训练时己方使用  $\epsilon$ -Greedy 还是随机策略，只要使用一次迭代更新 value function，训练出的模型就能完胜对手。
- 实验数据：

```
Episode 0: 1 successive wins, win_rate:1  
Test over: 61 wins in 100 games.  
Test over: 100 wins in 100 games.
```

如果测试时使用随机策略，胜率会下降到 60% 左右。如果使用训练后的模型对战，则胜率能达到 100%。

Game reset.

Board:

|   |   |   |
|---|---|---|
| - | - | - |
| - | - | - |
| - | - | - |

Next turn: X

Game reset.

Board:

|   |   |   |
|---|---|---|
| - | - | - |
| - | - | - |
| - | - | - |

Next turn: X

Game reset.

Board:

|   |   |   |
|---|---|---|
| - | - | - |
| - | - | - |
| - | - | - |

Next turn: X

Action (0,0) taken.

Board:

|   |   |   |
|---|---|---|
| X | - | - |
| - | - | - |
| - | - | - |

Next turn: O

Winner not found.

Action (0,1) taken.

Board:

|   |   |   |
|---|---|---|
| X | O | - |
| - | - | - |
| - | - | - |

Next turn: X

Winner not found.

Action (0,2) taken.

Board:

|   |   |   |
|---|---|---|
| X | O | X |
| - | - | - |

— — —  
Next turn: 0

Winner not found.

Action (1,0) taken.

Board:

|   |   |   |
|---|---|---|
| X | O | X |
| O | — | — |
| — | — | — |

Next turn: X

Winner not found.

Action (1,1) taken.

Board:

|   |   |   |
|---|---|---|
| X | O | X |
| O | X | — |
| — | — | — |

Next turn: 0

Winner not found.

Action (1,2) taken.

Board:

|   |   |   |
|---|---|---|
| X | O | X |
| O | X | O |
| — | — | — |

Next turn: X

Winner not found.

Action (2,0) taken.

Board:

|   |   |   |
|---|---|---|
| X | O | X |
| O | X | O |
| X | — | — |

Next turn: 0

Winner: X