

第五次作业实验报告

毛川 2300013218

Windy Gridworld

SARSA算法

代码解释:初始化状态 s , 利用 ϵ -greedy 策略选择动作 a , 执行动作 a , 观察奖励 r 和下一个状态 s' , 再使用 ϵ -greedy 策略选择下一个动作 a' , 然后根据 SARSA 更新 Q 值。如果未终止, 将 s' 和 a' 赋值给 s 和 a , 继续循环, 直到达到终止状态。

更新公式如下:

$$Q(s, a) \leftarrow Q(s, a) + \alpha (r + \gamma Q(s', a') - Q(s, a))$$

Q-Learning算法

代码解释:初始化状态 s , 利用 ϵ -greedy 策略选择动作 a , 执行动作 a , 观察奖励 r 和下一个状态 s' , 然后在 s' 遍历所有可能的动作, 得到最大的 Q' 值, 根据 Q' 更新 Q 值。直到达到终止状态。

更新公式如下:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left(r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right)$$

实验结果

编译运行代码, 得到以下结果: 由于采用了 ϵ -greedy 策略, 策略具有一定的随机性, 因此每次运行结果会有所不同。以下是我多次运行后得到的平均结果曲线: 两种算法的路径都小于 17 步, 符合预期。

```
Sarsa result:
(0,3)->(1,3)->(2,3)->(3,3)->(3,5)->(3,6)->(4,6)->(5,6)->(6,6)->(7,6)->(8,6)->(9,6)->(9,5)->(9,4)->(9,3)->(9,2)->(8,2)->(7,3).
Episode length: 17
Q learning result:
(0,3)->(1,3)->(2,3)->(3,3)->(4,4)->(5,5)->(6,6)->(7,6)->(8,6)->(9,6)->(9,5)->(9,4)->(9,3)->(9,2)->(8,2)->(7,3).
Episode length: 15
```