

基于 SQL 的数据分析实习

单人小组从任务一、任务二中选择一个，从任务三、任务四中选择一个完成；其他小组同时完成任务一和任务二，从任务三、四中选择一个完成。所有任务都可以参照提供的文档或自己通过询问大模型来得到参考 SQL 代码。

任务一：基于 SQL 的数据预处理

这个任务的主要内容是利用 SQL 中的正则表达式、字符串和日期函数，完成对原始数据集的清洗。具体工作内容可以参考“数据预处理实习任务设计”文档，同学们要完成的事情是跑通文档中的代码，加入 3~5 项新的清洗任务，比如加入一个新字段，要求满足特定表达式约束等，形成最终的清洗前后的对比结果报告。有兴趣的同学可以调用 Python 中数据质量评估工具，对清洗前后的数据质量做个对比。

任务二：针对 movielen 数据集的分析查询

1. 列出平均得分前 10 的电影。
2. 列出每个类型的平均得分前 10 的电影。
3. 列出每个用户综合评价排在前 5 的电影类型。
4. 列出每个用户观影次数排在前 5 的电影类型。
5. 列出兴趣相同的用户对，主要是基于他们相同的观影记录做分析，满足如下条件：
 - ◆ 统计每个类型下他们相同观影的次数，设置一个阈值，过滤掉那些相同观影次数太低的类型，剩下的相同观影类型的个数不少于一个阈值。
 - ◆ 他们观看相同电影时所给出的评价分的差值的标准差不大于一个阈值。

任务三：基于 SQL 实现各种熵的概念

熵是机器学习领域最基础最重要的概念，基于 SQL 实现各种熵，是数据库内置机器学习算法的基础。各种熵的概念以及如何用 SQL 实现它们，同学们可以参照“用 SQL 实现机器学习中的基础概念-熵”文档中的内容。

我们的实习任务是将上面的熵应用到“世界幸福指数数据集”上面，看看可以得到哪些有

意义的结论。“世界幸福指数数据集”各字段含义见文档说明。

任务四：基于 SQL 实现各种损失函数

同样，损失函数是机器学习算法的核心，各种损失函数的定义以及如何用 SQL 实现它们，同学们可以参照“用 SQL 实现机器学习中的基础概念-损失函数”文档中的内容。

我们的实习任务是“世界幸福指数数据集”实现上面的损失函数，同时选择合适的某个损失函数，实现一个机器学习算法，比如逻辑回归、决策树、或者聚类算法。也可以选择线性回归算法，看看应用不同损失函数的效果如何。

基于 SQL 的多元线性回归

定义如下幸福指数数据表 `happyness(Overall_rank, Country, Score, GDP_per_capita, Social_support, Healthy_life_expectancy, Freedom_to_make_life_choices, Generosity, Perceptions_of_corruption)`。请以 `score` 作为因变量，`GDP_per_capita, Social_support, Healthy_life_expectancy, Freedom_to_make_life_choices, Generosity, Perceptions_of_corruption` 作为自变量，用 SQL 完成多元线性回归算法。

基于 SQL 的决策树

定义如下幸福指数数据表 `happyness(Overall_rank, Country, Score, GDP_per_capita, Social_support, Healthy_life_expectancy, Freedom_to_make_life_choices, Generosity, Perceptions_of_corruption)`，`score` 被划分为 `high, middle, low` 三个类别（这个请自己选择划分区间）。请以 `score` 作为分类属性，用 SQL 完成决策树分类算法。

基于 SQL 的聚类

定义如下幸福指数数据表 `happyness(Overall_rank, Country, Score, GDP_per_capita, Social_support, Healthy_life_expectancy, Freedom_to_make_life_choices, Generosity, Perceptions_of_corruption)`。

请选择属性 `Score, GDP_per_capita, Social_support, Healthy_life_expectancy, Freedom_to_make_life_choices, Generosity, Perceptions_of_corruption`，对它们进行归一化处理，并用归一化之后的结果来计算样本之间的距离，用 SQL 完成 `k-means` 算法，指定 `k=3`。